

Avaliação Estatística da Eficiência de Dados do PEDS: Uma Abordagem Estrutural com um Surrogate de Baixa Fidelidade Não-Físico

Nome do Autor¹

¹Instituição – Departamento
Cidade – Estado – Brasil

email@dominio.br

Abstract. *Physics-Enhanced Deep Surrogates (PEDS) reach the accuracy of a neural baseline using far fewer training samples by coupling a learned generator to a low-fidelity physics solver [Pestourie et al. 2023]. Is the embedded physics essential to this data efficiency, or does the structural coupling alone explain it? Using the original PEDS diffusion benchmarks (Fourier and Fisher), we replace the differentiable physics solver with a non-physical affine readout of the same generated geometry, leaving the generator and the coarse-geometry mixing untouched. We compare the physical PEDS, this affine variant, and the neural baseline over a sweep of training-set sizes, each as a 10-seed ensemble, with the fractional error as metric. Learning-curve exponents and non-parametric tests (Wilcoxon, Friedman) over the problem axis [Demšar 2006] quantify whether dropping the physics changes convergence. The design tests, on physical data, whether the PEDS advantage is physical or structural.*

Resumo. *Os Surrogates com Física Embutida (PEDS) atingem a acurácia de uma rede neural com muito menos dados de treino, acoplando um gerador aprendido a um solver físico de baixa fidelidade [Pestourie et al. 2023]. A física embutida é essencial para essa eficiência, ou o acoplamento estrutural sozinho a explica? Nos próprios benchmarks de difusão do PEDS (Fourier e Fisher), trocamos o solver físico por uma leitura afim não-física da mesma geometria gerada, preservando o gerador e a mistura com a geometria coarse. Comparamos o PEDS físico, essa variante afim e o baseline neural ao longo de uma varredura do tamanho do treino, cada um como ensemble de dez sementes, medindo o erro fracionário. Testes de Wilcoxon e Friedman sobre o eixo dos problemas [Demšar 2006] medem se remover a física altera a convergência.*

1. Introdução

Simular propriedades de sistemas governados por equações diferenciais parciais (EDPs) tipicamente exige solvers numéricos de alta fidelidade cujo custo inviabiliza tarefas que demandam milhares de avaliações, como a otimização de projeto ou os problemas inversos. Modelos *surrogate* treinados por aprendizado de máquina contornam esse gargalo ao aproximar o mapa entre parâmetros e a propriedade de interesse a uma fração do custo de inferência. O custo, porém, não desaparece: migra para a geração do conjunto de treino, que ainda depende do solver caro [Karniadakis et al. 2021]. Quanto mais exemplos um

surrogate exige para atingir uma acurácia-alvo, menor é o benefício líquido que ele entrega, e a eficiência de dados passa a ser a métrica de primeira ordem para esse tipo de modelo.

Os *Physics-Enhanced Deep Surrogates* (PEDS) atacam diretamente essa eficiência [Pestourie et al. 2023]. Em vez de aprender o mapa com uma rede neural isolada, o PEDS acopla um solver físico de baixa fidelidade, barato e diferenciável, a um gerador neural treinado de ponta a ponta: a rede aprende a fornecer ao solver grosseiro uma geometria que o leva a reproduzir a saída de alta fidelidade. Como o solver já impõe o comportamento qualitativo correto, a rede precisa aprender apenas a correção que falta. O ganho reportado é expressivo, com o PEDS alcançando a acurácia de uma rede convencional usando uma fração dos exemplos de treino, efeito atribuído ao conhecimento físico embutido, que atuaria como viés indutivo.

Essa explicação deixa uma pergunta em aberto. O ganho decorre de o solver embutido ser *fisicamente correto*, ou decorre, de forma mais geral, de simplesmente acoplar um *modelo estruturado de baixa fidelidade* que carregue informação útil sobre o alvo? A distinção tem consequência prática direta. Se a vantagem for intrinsecamente física, ela fica restrita a domínios que dispõem de um solver *coarse*; se for um efeito estrutural mais amplo, o mesmo mecanismo poderia valer mesmo sem física, bastando uma estrutura de baixa fidelidade barata.

Este trabalho responde à pergunta sem sair dos dados do próprio PEDS. Usamos os benchmarks de difusão do artigo original e fazemos uma única intervenção controlada: trocamos o solver físico de baixa fidelidade por uma leitura afim não-física da mesma geometria gerada, deixando o gerador e a mistura com a geometria coarse exatamente como estão. Comparamos então o PEDS físico, essa variante afim e o baseline neural do artigo, ao longo de uma varredura do tamanho do conjunto de treino, com cada modelo avaliado como ensemble de dez sementes e o erro fracionário como métrica. A comparação segue um protocolo estatístico não-paramétrico [Demšar 2006], atento à variância de sementes [Bouthillier et al. 2021].

A contribuição é mostrar, sobre dados físicos, se a eficiência de dados do PEDS depende da resolução física ou apenas do acoplamento estrutural. A intervenção é mínima e local, o que torna a leitura limpa: o PEDS e a variante afim diferem em um único componente, e qualquer diferença de convergência se atribui a ele. A avaliação é estatística e reproduzível, baseada em curvas de aprendizado e ensembles, e não em uma execução única.

2. Fundamentação Teórica e Trabalhos Relacionados

2.1. Surrogates de EDPs, Eficiência de Dados e Maldição da Dimensionalidade

Um surrogate aprende a mapear parâmetros de entrada, como geometrias ou coeficientes, para uma quantidade de saída, substituindo o solver de alta fidelidade nas etapas em que ele seria chamado repetidamente. A promessa é amortizar um custo de treino fixo em muitas avaliações baratas. O obstáculo central é que redes neurais profundas, sem estrutura adicional, costumam exigir grandes volumes de dados para generalizar bem [Karniadakis et al. 2021], e cada exemplo de treino carrega o custo de uma chamada ao solver caro. Em problemas científicos esse orçamento de dados costuma ser o recurso mais escasso.

A dificuldade se agrava com a dimensionalidade. À medida que o espaço de parâmetros cresce, o número de amostras necessárias para cobri-lo de forma representativa aumenta rapidamente, a chamada maldição da dimensionalidade, e a eficiência de dados deixa de ser uma conveniência para decidir se o surrogate é viável [Pestourie et al. 2023]. É nesse ponto que embutir estrutura conhecida no modelo se torna atraente: ao reduzir o espaço de funções que a rede precisa explorar, espera-se atingir a mesma acurácia com menos dados.

2.2. PEDS e Aprendizado Multi-fidelidade: o Modelo de Baixa Fidelidade como Prior

O PEDS materializa essa ideia acoplando dois componentes [Pestourie et al. 2023]. Um gerador neural recebe os parâmetros de entrada e produz uma geometria coarse, que é então processada por um solver físico de baixa fidelidade, diferenciável e barato. O conjunto é treinado de ponta a ponta para casar a saída de alta fidelidade. Como o solver já impõe o comportamento qualitativo correto, a rede precisa aprender apenas a correção que falta, e não o mapa inteiro a partir do zero.

Visto sob esse ângulo, o PEDS é um caso de aprendizado multi-fidelidade, em que um modelo barato e impreciso é combinado a dados caros e precisos para reduzir a necessidade destes últimos. O princípio é geral e não pressupõe física: em operadores neurais multi-fidelidade, acoplar uma fonte de baixa fidelidade reduz de forma substancial a quantidade de dados de alta fidelidade necessária para um dado nível de erro [Lu et al. 2022]. É essa leitura que motiva a pergunta do trabalho, pois se o ganho do PEDS é, no fundo, multi-fidelidade, a natureza física do componente de baixa fidelidade pode não ser essencial.

2.3. Viés Indutivo: Física versus Arquitetura

Embutir conhecimento sobre o problema em um modelo é, em essência, impor um viés indutivo: restringe-se a classe de funções aprendíveis na direção de soluções plausíveis, o que tende a reduzir a complexidade amostral e a melhorar a generalização [Karniadakis et al. 2021]. A física é uma fonte particularmente rica desse viés, mas não é a única. Um corretor de baixa fidelidade informativo, ainda que não-físico, também restringe o espaço de hipóteses.

A hipótese que examinamos é que o ganho de eficiência de dados do PEDS pode ser um efeito desse viés estrutural, ou seja, de haver um componente de baixa fidelidade acoplado que já carrega parte do sinal, e não da resolução física em si. Distinguir as duas explicações exige manter tudo constante e mexer só na física. É o que fazemos ao substituir o solver físico do PEDS por uma leitura afim não-física e medir se a vantagem sobrevive. A resposta a essa pergunta, obtida sobre os próprios dados físicos do PEDS, é a contribuição central do artigo.

3. Metodologia

3.1. Dados e Métrica

Usamos os conjuntos de dados de difusão do trabalho original do PEDS [Pestourie et al. 2023], nas variantes Fourier(d) e Fisher(d) com $d \in \{16, 25\}$. Cada amostra associa um vetor de parâmetros de entrada, que descreve a geometria, a um

fluxo escalar κ obtido por um solver de alta fidelidade; cada base contém 10 000 pares. A geometria coarse manipulada pelo modelo é uma grade $\sqrt{d} \times \sqrt{d}$, isto é, 4×4 para $d = 16$ e 5×5 para $d = 25$. Nossa implementação do solver coarse foi validada contra o artigo: o erro fracionário de baixa fidelidade puro em Fourier(16) ficou em 0,140, próximo do 0,135 reportado.

A métrica é o erro fracionário (FE), $\|\hat{y} - y\|/\|y\|$ no conjunto de teste, a mesma do artigo, o que permite comparar diretamente com os valores publicados.

3.2. Modelos Comparados

Comparamos três modelos sobre a mesma tarefa física. O **PEDS** é o modelo original: um gerador neural produz a geometria $\sqrt{d} \times \sqrt{d}$, que é combinada com uma geometria coarse barata e entregue ao solver físico de difusão diferenciável, o qual resolve a EDP e devolve o fluxo κ . O **PEDS-afim** é idêntico, exceto por um ponto: o solver físico é substituído por uma leitura afim, $\hat{\kappa} = \mathbf{a}^\top \text{vec}(\text{geom}) + b$. O gerador e a mistura com a geometria coarse permanecem intactos; apenas a resolução física da EDP sai de cena. O **baseline** é o modelo puramente data-driven (NN-only) do artigo, em que o solver é trocado por camadas densas treináveis.

Esse desenho isola exatamente a contribuição da física. O PEDS e o PEDS-afim diferem só no passo de baixa fidelidade, físico contra afim não-físico, com todo o resto fixo. A parte aprendível, o gerador, segue treinável no PEDS-afim, de modo que o modelo ainda aprende e a comparação é justa. A geometria coarse de baixa fidelidade também é mantida no PEDS-afim, então a variante preserva a estrutura multifidelidade [Lu et al. 2022] e abre mão apenas da física. Note que, com a leitura afim no lugar do solver, o PEDS-afim se aproxima de uma rede neural convencional com um gargalo do tamanho da geometria; é precisamente essa aproximação que torna o contraste com o PEDS físico informativo.

3.3. Protocolo: Sweep de N, Sementes e Early Stopping

A eficiência de dados é medida como uma curva de aprendizado: o FE de teste em função do tamanho do conjunto de treino N [Viering and Loog 2023]. Cada base tem 10 000 amostras; reservamos blocos fixos para validação e teste e variamos N em uma grade logarítmica no restante, com cerca de 7 900 amostras de treino disponíveis, por exemplo $N \in \{64, 128, 256, 512, 1024, 2048, 4096\}$. O regime de poucos dados, da ordem de 10^2 a 10^3 , é justamente onde a vantagem do PEDS é reivindicada. Cada combinação de modelo e N é um ensemble de dez sementes, de modo que cada ponto da curva é uma distribuição, e não um valor isolado; a variância de inicialização e de amostragem é grande o bastante para inverter conclusões a partir de uma única execução [Bouthillier et al. 2021].

Os conjuntos de validação e de teste são fixos e comuns a todos os modelos, garantindo que a comparação seja feita sobre os mesmos dados. O treino usa Adam, lotes de 64 e perda de Huber. Para que a varredura compare tamanhos de dados, e não orçamentos de otimização, interrompemos o treino por validação (*early stopping*) em vez de fixar o número de épocas, já que com épocas fixas um N grande recebe muito mais atualizações de gradiente que um N pequeno [Viering and Loog 2023].

3.4. Avaliação Estatística

Tratamos cada valor de N como um problema e seguimos a metodologia de comparação não-paramétrica de modelos [Demšar 2006]. Ajustamos uma lei de potência $FE \sim N^\alpha$ a cada modelo e comparamos os expoentes, já que um $|\alpha|$ maior indica convergência mais rápida em dados [Viering and Loog 2023].

A inferência combina níveis de agregação. O contraste central, PEDS contra PEDS-afim, é avaliado por um teste de Wilcoxon de postos sinalizados sobre o eixo dos N , que diz se remover a física desloca a curva de forma consistente. Em cada N , um Wilcoxon pareado sobre as dez sementes localiza onde a diferença é significativa, e um teste de Friedman compara os três modelos, com pós-teste quando a hipótese nula é rejeitada. Reportamos a contagem de rejeições e o tamanho dos efeitos, não um p -valor isolado.

A leitura é direta. Se o PEDS-afim acompanhar o PEDS, com expoentes e FE estatisticamente indistinguíveis, e ambos superarem o baseline, a resolução física não é essencial: o acoplamento estrutural explica a eficiência de dados. Se o PEDS mantiver vantagem significativa sobre o PEDS-afim, a física faz trabalho real que a leitura afim não captura.

4. Resultados e Discussão

4.1. Eficiência de Dados: Curvas $FE \times N$ e Expoentes de Escala

4.2. Análise Estatística: PEDS vs PEDS-afim

4.3. Física ou Estrutura? Interpretação e Limitações

5. Conclusão e Trabalhos Futuros

Agradecimentos

Referências

- Bouthillier, X., Delaunay, P., Bronzi, M., Trofimov, A., Nichyporuk, B., Szeto, J., Mohammadi Sepahvand, N., Raff, E., Madan, K., Voleti, V., Ebrahimi Kahou, S., Michalski, V., Arbel, T., Pal, C., Varoquaux, G., and Vincent, P. (2021). Accounting for variance in machine learning benchmarks. In *Proceedings of Machine Learning and Systems (MLSys)*, volume 3.
- Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7:1–30.
- Karniadakis, G. E., Kevrekidis, I. G., Lu, L., Perdikaris, P., Wang, S., and Yang, L. (2021). Physics-informed machine learning. *Nature Reviews Physics*, 3(6):422–440.
- Lu, L., Pestourie, R., Johnson, S. G., and Romano, G. (2022). Multifidelity deep neural operators for efficient learning of partial differential equations with application to fast inverse design of nanoscale heat transport. *Physical Review Research*, 4(2):023210.
- Pestourie, R., Mroueh, Y., Rackauckas, C., Das, P., and Johnson, S. G. (2023). Physics-enhanced deep surrogates for partial differential equations. *Nature Machine Intelligence*, 5(12):1458–1465.
- Viering, T. and Loog, M. (2023). The shape of learning curves: A review. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(6):7799–7819.